



Data Warehouse and Business Intelligence

Tugas Kelompok: Pembentukan Data Mart dan Visualisasi Data

**Dosen Pengampu
Khabib Mustofa**

August 26, 2026



Daftar Isi

Index i
1 Multidimensional Data Modelling (Studi Kasus: Perjalanan Bus Antarkota Multi-Leg dan Loyalitas Penumpang) 1
1.1 Pendahuluan 1
1.1.1 Deskripsi Domain 1
1.1.2 Latar Belakang 1
1.1.3 Tujuan 2
1.2 Analisis Kebutuhan Bisnis 2
1.2.1 Stakeholder Bisnis 2
1.2.2 Proses Bisnis yang Dimodelkan 3
1.2.3 Business Questions 3
1.2.4 Sumber Data yang Relevan 3
1.3 Perancangan Dimensional Modeling 4
1.3.1 Penentuan Grain 4
1.3.2 Pemetaan Proses Bisnis 5
1.3.3 Perancangan Fact Table 5
1.3.4 Perancangan Dimension Table 6
1.3.5 Slowly Changing Dimensions 7
1.3.6 Diagram Skema Dimensional 8
1.4 Synthetic Data Generation 8
1.4.1 Strategi Pembuatan Data Sintetis 8
1.4.2 Kode Generator 9
1.4.3 Contoh Data Mentah 10
1.4.4 Skema Sumber 10
1.5 Data Mart 11
1.5.1 Skema Final Data Mart 11
1.5.2 Dokumentasi Tabel dan Kolom 12



1.5.3	Koneksi ke BI Tools	12
1.5.4	Semantic Layer	12
1.6	Verifikasi dan Validasi	13
1.6.1	Query Analitik	13
1.6.2	Hasil Query	15
1.6.3	Data Quality Check	16
1.7	Kesimpulan dan Refleksi	17
1.7.1	Kesimpulan	17
1.7.2	Tantangan yang Dihadapi	17
1.7.3	Keputusan Desain Utama	18
1.7.4	Kesiapan Data Mart untuk Visualisasi	18
1.8	Referensi	18
2	Visualisasi	19
2.1	Skenario dan Pengguna Dashboard	19
2.2	Tools Visualisasi	19
2.2.1	Tableau	19
2.2.2	Python-based Tools	19
2.3	Perancangan Dashboard	20
2.3.1	Definisi Metrik	20
2.4	Implementasi Python-based Tools	20
2.4.1	Hasil Dashboard Python	20
2.5	Hasil Implementasi Tableau	24
2.5.1	Konfigurasi Data Source	24
2.5.2	Dashboard Kinerja Operasional dan Dampak Finansial	26
2.5.3	Dashboard Loyalitas dan Perilaku Penumpang	26
2.5.4	Dashboard Aktivitas Transaksi Loyalitas	27
2.6	Pembahasan	27
2.7	Kesimpulan	28



BAB 1

Multidimensional Data Modelling (Studi Kasus: Perjalanan Bus Antarkota Multi-Leg dan Loyalitas Penumpang)

Anggota Kelompok

- 1. Citra Putri Saragih (25/574147/PPA/07239)
- 2. Ade Dwi Putra (25/574144/PPA/07237)

1.1 PENDAHULUAN

1.1.1 Deskripsi Domain

Domain yang dipilih adalah transportasi publik dengan fokus pada perjalanan bus antarkota dengan beberapa segmen (*multi-leg*) dan loyalitas penumpang. Dalam studi kasus ini, satu rencana perjalanan (*itinerary*) dapat terdiri atas lebih dari satu segmen perjalanan (*leg*). Penumpang dapat berpindah bus di terminal transit sebelum mencapai tujuan akhir.

Ruang lingkup studi kasus mencakup tiga proses bisnis berikut:

- a. Penjualan tiket: pencatatan pembelian tiket untuk suatu rencana perjalanan.
- b. Pelaksanaan perjalanan: pencatatan jadwal serta realisasi keberangkatan dan kedatangan pada setiap segmen perjalanan.
- c. Transaksi loyalitas: pencatatan perolehan, penukaran, penyesuaian, dan kedaluwarsa poin milik penumpang.

Ketiga proses tersebut dipilih agar kinerja operasional perjalanan, dampak finansial, dan aktivitas loyalitas penumpang dapat dianalisis secara terintegrasi. Seluruh data dalam studi kasus ini, termasuk data penumpang, armada, terminal, jadwal, dan transaksi, dibuat secara sintetis dan tidak merepresentasikan apapun yang ada di dunia nyata.

1.1.2 Latar Belakang

Sistem operasional perusahaan bus antarkota dirancang untuk mendukung transaksi harian, seperti pemesanan kursi, penjadwalan armada, dan pemrosesan pembayaran. Sistem ini menggunakan basis data *Online Transaction Processing* (OLTP) yang mengutamakan kecepatan dan ketepatan dalam melakukan



pencatatan transaksi. Struktur data OLTP umumnya ternormalisasi dan tersebar pada sejumlah tabel sehingga sesuai untuk proses *insert*, *update*, dan *delete*. Akan tetapi kurang praktis jika digunakan langsung untuk analisis historis yang melibatkan banyak tabel dan periode waktu yang panjang.

Kebutuhan analisis akan menjadi lebih kompleks pada perjalanan bus antarkota dengan beberapa segmen. Keterlambatan pada satu segmen dapat mengurangi waktu transit dan menyebabkan penumpang gagal melanjutkan perjalanan dengan bus berikutnya (*missed connection*). Kondisi tersebut dapat menimbulkan proses pemesanan ulang, pengembalian dana, atau pemberian kompensasi. Manajemen perlu melihat hubungan antara gangguan perjalanan, kerugian pendapatan, dan kemungkinan penumpang melakukan pemesanan kembali. Analisis lintas proses dan lintas waktu seperti ini sulit dilakukan secara langsung pada sistem transaksi harian.

Oleh karena itu, data warehouse diperlukan untuk mengintegrasikan data penjualan tiket, pelaksanaan perjalanan, dan transaksi loyalitas ke dalam struktur yang mendukung analisis historis. Perancangan pada tugas ini menggunakan metodologi Kimball Dimensional Modeling karena dimulai dari proses bisnis dan menghasilkan data mart yang dapat digunakan untuk menjawab kebutuhan analitik serta menjadi sumber data bagi tahap visualisasi.

1.1.3 Tujuan

Berdasarkan latar belakang tersebut, tugas ini bertujuan untuk:

- menganalisis kebutuhan bisnis para pemangku kepentingan pada layanan bus antarkota, terutama yang berkaitan dengan ketepatan waktu operasional, potensi kehilangan pendapatan, dan loyalitas penumpang;
- merancang skema dimensional berbentuk *star schema*, termasuk menentukan *grain*, *fact table*, *dimension table*, dan strategi *Slowly Changing Dimension* (SCD) untuk atribut yang dapat berubah, seperti tingkat loyalitas penumpang;
- membangun dataset sintesis yang merepresentasikan data operasional mentah, termasuk variasi musim sibuk, insiden gagal melanjutkan perjalanan pada saat transit, pembatalan, dan kompensasi;
- mengimplementasikan pipeline ETL/ELT untuk mentransformasikan data mentah menjadi data mart yang terdokumentasi dan memiliki relasi antartabel yang konsisten; dan
- melakukan verifikasi dan validasi data mart melalui query analitik yang menjawab kebutuhan bisnis serta memastikan bahwa data mart dapat digunakan sebagai sumber data pada tahap visualisasi.

1.2 ANALISIS KEBUTUHAN BISNIS

1.2.1 Stakeholder Bisnis

Analisis kebutuhan bisnis difokuskan pada tiga fungsi manajemen yang menjadi pengguna utama data mart:

- VP of Operations* – bertanggung jawab atas ketepatan jadwal keberangkatan dan kedatangan armada bus. *Stakeholder* ini membutuhkan visibilitas mengenai *bottleneck* di terminal, rasio *missed connection* akibat keterlambatan, serta kinerja rute dan armada spesifik dalam memenuhi *Service Level Agreement* (SLA) ketepatan waktu.
- VP of Commercial and Revenue Management* – bertanggung jawab atas profitabilitas perusahaan. *Stakeholder* ini berfokus pada pemantauan pendapatan tiket, *load factor* (keterisian kursi) per rute, efektivitas pemberian diskon, serta kuantifikasi *revenue leakage* yang diakibatkan oleh *refund*, *rebooking*, atau denda kompensasi operasional.
- Head of Customer Loyalty* – bertanggung jawab atas retensi pelanggan jangka panjang. *Stakeholder* ini membutuhkan analisis terkait dinamika perubahan *loyalty tier*, pola perolehan dan penukaran poin, tingkat *repeat booking*, serta ingin melihat apakah terdapat asosiasi atau korelasi negatif antara



gangguan perjalanan yang dialami pelanggan dengan tingkat retensi mereka.

Ketiga *stakeholder* ini dipilih karena saling melengkapi: pihak Operasional berfokus pada kualitas eksekusi di lapangan, pihak Komersial mengevaluasi dampaknya secara finansial, dan pihak Loyalty mengukur dampak jangka panjangnya terhadap perilaku konsumen.

1.2.2 Proses Bisnis yang Dimodelkan

Untuk menjawab kebutuhan ketiga *stakeholder* di atas, tiga proses bisnis pada Bagian 1.1.1 dipetakan ke dalam tabel matriks berikut:

Tabel 1.1: Matriks Proses Bisnis dan Fact Table

Proses Bisnis	Fact Table (Rencana)	Stakeholder Utama
Penjualan Tiket	<code>fct_ticket_sales</code>	VP Commercial & Revenue (pendapatan tiket, diskon, <i>load factor</i>)
Perjalanan <i>Itinerary</i> (Leg)	<code>fct_passenger_itinerary_leg</code>	VP of Operations (ketepatan waktu, <i>missed connection</i> , kompensasi)
Transaksi Loyalitas	<code>fct_loyalty_transaction</code>	Head of Customer Loyalty (<i>loyalty tier</i> , poin, <i>repeat booking</i>)

Ketiga *fact table* tersebut akan berbagi *conformed dimension* yang sama, antara lain `dim_passenger`, `dim_route`, dan `dim_date`, sehingga analisis lintas proses—misalnya menghubungkan insiden *missed connection* yang dicatat di tabel perjalanan dengan aktivitas *redeem* poin di tabel loyalitas—dapat dilakukan secara konsisten.

1.2.3 Business Questions

Manajemen Operasional & Komersial

1. Terminal transit dan pasangan rute manakah yang mencatatkan *missed connection rate* tertinggi selama periode observasi?
2. Rute operasional dan armada bus manakah yang memiliki *arrival delay* (keterlambatan kedatangan) serta *SLA breach rate* tertinggi?
3. Berapa total *revenue leakage* absolut yang diakibatkan oleh proses *refund*, *rebooking*, dan kompensasi uang tunai pada setiap rute selama musim sibuk (*peak season*)?

Manajemen Loyalitas Pelanggan (Customer Loyalty)

4. Bagaimana perbedaan tingkat frekuensi perjalanan, pendapatan kotor rata-rata, dan pola penggunaan *loyalty points* pada setiap *loyalty tier* (misal: Basic, Gold, Platinum)?
5. Apakah terdapat korelasi atau asosiasi antara penumpang yang pernah mengalami insiden *missed connection* dengan *repeat booking rate* yang lebih rendah dibandingkan penumpang tanpa riwayat gangguan operasional?

1.2.4 Sumber Data yang Relevan

Untuk menjawab *business questions* di atas, data mentah (*raw/source data*) operasional sintetis yang dibutuhkan dan akan dibangkitkan pada Tahap 3 meliputi:



- **Tabel Pelanggan** (*raw_passengers*): Memuat data identitas pelanggan, riwayat kontak, dan status segmentasi program loyalitas.
- **Tabel Pemesanan & Tiket** (*raw_bookings*, *raw_ticket_legs*): Memuat data transaksi pemesanan, nilai tarif dasar, diskon, dan rincian perjalanan per segmen rute (*leg*).
- **Tabel Jadwal Bus** (*raw_bus_schedules*): Memuat kapasitas armada, rute, dan jadwal terencana (keberangkatan/kedatangan).
- **Tabel Log Operasional** (*raw_trip_events*): Memuat pencatatan waktu aktual armada tiba dan berangkat di tiap terminal, yang menjadi dasar kalkulasi *delay*.
- **Tabel Riwayat Loyalitas** (*raw_loyalty_transactions*): Merekam histori mutasi penambahan dan pengurangan poin pelanggan.
- **Tabel Klaim & Kompensasi** (*raw_compensation_claims*): Mencatat insiden *refund* atau kompensasi finansial akibat kegagalan SLA.

Sumber data mentah tersebut menjadi dasar perancangan dimensional modeling dan acuan struktur bagi *synthetic data generator* yang dikembangkan.

1.3 PERANCANGAN DIMENSIONAL MODELING

1.3.1 Penentuan Grain

Grain menentukan makna dari satu baris pada fact table. Penentuan grain dilakukan sebelum memilih dimensi dan measure agar data dari proses bisnis yang berbeda tidak tercampur dalam satu tingkat detail. Rancangan ini menggunakan grain atomik untuk mempertahankan detail transaksi dan perjalanan yang diperlukan dalam analisis.

Grain Setiap Fact Table

- fct_ticket_sales*: satu baris merepresentasikan satu tiket milik satu penumpang untuk satu *itinerary leg* pada saat transaksi pembelian berhasil. Jika satu *itinerary* terdiri atas beberapa *leg*, nilai tarif, diskon, dan pajak dialokasikan ke setiap *leg* agar pendapatan tidak dihitung berulang.
- fct_passenger_itinerary_leg*: satu baris merepresentasikan satu penumpang pada satu *leg* dalam satu perjalanan bus terjadwal. Baris diperbarui ketika penumpang melewati tahapan perjalanan, mulai dari pemesanan sampai penyelesaian gangguan atau klaim jika ada.
- fct_loyalty_transaction*: satu baris merepresentasikan satu transaksi poin milik satu penumpang, baik berupa perolehan, penukaran, penyesuaian, maupun kedaluwarsa poin.

Alasan Pemilihan Grain

Grain per tiket-leg pada penjualan dipilih agar pendapatan dapat dianalisis sampai tingkat segmen rute. Grain per penumpang-leg pada pelaksanaan perjalanan digunakan karena dampak gangguan dapat berbeda untuk setiap penumpang, terutama pada *itinerary* yang memiliki terminal transit. Transaksi loyalitas dipisahkan karena mutasi poin dapat terjadi di luar perjalanan, misalnya ketika poin kedaluwarsa atau mendapat penyesuaian manual.

Implikasi terhadap Granularitas dan Performa Query

Grain atomik akan menghasilkan jumlah baris yang lebih besar dibandingkan tabel yang sudah diagregasi. Meskipun demikian, data masih dapat diringkas berdasarkan tanggal, rute, terminal, atau penumpang



sesuai kebutuhan analisis. Nilai keterlambatan bus yang muncul pada beberapa baris penumpang tidak boleh langsung dijumlahkan. Analisis keterlambatan perlu menggunakan rata-rata pengalaman penumpang atau terlebih dahulu dikelompokkan berdasarkan `trip_id` agar satu perjalanan bus tidak dihitung berulang.

1.3.2 Pemetaan Proses Bisnis

Business Process dan Fact Table

Setiap proses bisnis utama dipetakan ke fact table sebagai berikut:

Proses bisnis	Fact table	Jenis fact table
Penjualan tiket	<code>fct_ticket_sales</code>	Transaction fact table
Pelaksanaan perjalanan	<code>fct_passenger_itinerary_leg</code>	Accumulating snapshot
Transaksi loyalitas	<code>fct_loyalty_transaction</code>	Transaction fact table

Conformed Dimensions

Ketiga fact table menggunakan dimensi yang konsisten agar hasil dari proses bisnis yang berbeda dapat dibandingkan. `dim_passenger` dan `dim_date` digunakan oleh seluruh fact table. `dim_route` digunakan bersama oleh fact penjualan dan perjalanan, sedangkan `dim_terminal` dan `dim_bus_fleet` terutama digunakan pada fact perjalanan. Pemetaan ini akan dirangkum kembali dalam bus matrix setelah seluruh atribut dimensi ditetapkan.

1.3.3 Perancangan Fact Table

Jenis Fact Table

`fct_ticket_sales` dan `fct_loyalty_transaction` menggunakan jenis transaction fact table karena setiap baris dicatat untuk satu kejadian transaksi. `fct_passenger_itinerary_leg` menggunakan accumulating snapshot karena satu baris diperbarui ketika tahapan perjalanan penumpang berlangsung.

Measures dan Klasifikasi Aditivitas

Measure utama pada setiap fact table dirancang sebagai berikut:

- `fct_ticket_sales`: `allocated_base_fare`, `discount_amount`, `tax_amount`, `net_ticket_revenue`, `loyalty_points` dan `loyalty_points_redeemed`. Seluruh nilai tersebut additive karena dicatat sebagai nilai per tiket-leg dan dapat dijumlahkan pada semua dimensi.
- `fct_passenger_itinerary_leg`: `missed_connection_count`, `rebooking_cost`, `refund_amount`, dan `compensation_amount` bersifat additive. `departure_delay_minutes`, `arrival_delay_minutes`, `scheduled_connection_minutes` dan `actual_connection_minutes` bersifat non-additive karena penjumlahan durasi dari beberapa perjalanan atau penumpang tidak selalu memiliki makna.
- `fct_loyalty_transaction`: `points_transacted` bersifat additive dengan nilai positif untuk poin masuk dan negatif untuk poin keluar. `points_balance_after` bersifat non-additive dan digunakan sebagai saldo terakhir setelah suatu transaksi.

Foreign Keys

Foreign key yang direncanakan meliputi:



- `fct_ticket_sales`: `passenger_sk`, `booking_date_sk`, `booking_time_sk`, `route_sk`, `sales_context_sk`, dan `promotion_sk`;
- `fct_passenger_itinerary_leg`: `passenger_sk`, `route_sk`, `bus_fleet_sk`, `origin_terminal_sk`, `destination_terminal_sk`, `disruption_reason_sk`, serta `date key` dan `time key` untuk jadwal dan realisasi keberangkatan maupun kedatangan; dan
- `fct_loyalty_transaction`: `passenger_sk`, `transaction_date_sk`, `transaction_time_sk`, dan `loyalty_transaction_type_sk`;

Degenerate Dimensions

Nomor transaksi yang diperlukan untuk penelusuran tetapi tidak memiliki atribut deskriptif disimpan langsung pada fact table. Atribut tersebut meliputi `booking_id`, `ticket_number`, dan `itinerary_id` pada fact penjualan; `ticket_number`, `itinerary_id`, dan `trip_id` pada fact perjalanan; serta `loyalty_transaction_id` pada fact transaksi loyalitas.

1.3.4 Perancangan Dimension Table

Surrogate Keys dan Atribut Dimensi

Setiap dimension table menggunakan surrogate key bertipe integer sebagai primary key dan tetap menyimpan natural key dari sistem sumber. Dimensi yang direncanakan terdiri atas:

- `dim_date`: tanggal, hari, nama hari, minggu, bulan, kuartal, tahun, dan penanda musim sibuk;
- `dim_time`: jam, menit, kelompok waktu, dan penanda jam sibuk;
- `dim_passenger`: ID penumpang, nama, kota domisili, tanggal registrasi, dan tingkat loyalitas;
- `dim_terminal`: ID terminal, nama terminal, kota, provinsi, dan kapasitas terminal;
- `dim_route`: ID rute, nama rute, jarak, dan estimasi waktu perjalanan;
- `dim_bus_fleet`: ID armada, nomor pelat, kelas bus, konfigurasi kursi, tahun produksi, dan kapasitas kursi;
- `dim_sales_context`: kelas tarif, kanal pemesanan, metode pembayaran, dan penanda tiket dapat dikembalikan;
- `dim_promotion`: kode, nama, dan jenis promosi;
- `dim_disruption_reason`: kategori dan tingkat keparahan gangguan; dan
- `dim_loyalty_transaction_type`: jenis mutasi poin.

Hierarki Dimensi

Hierarki yang digunakan antara lain tanggal menuju bulan, kuartal, dan tahun pada `dim_date`; terminal menuju kota dan provinsi pada `dim_terminal`; serta kelas bus menuju jenis konfigurasi kursi pada `dim_bus_fleet`. Hierarki ini digunakan untuk melakukan analisis dari tingkat detail menuju tingkat ringkasan.



Role-Playing Dimensions

`dim_date` dan `dim_time` digunakan dalam beberapa peran, seperti tanggal dan waktu pemesanan, keberangkatan terjadwal, keberangkatan aktual, kedatangan terjadwal, serta kedatangan aktual. `dim_terminal` juga digunakan sebagai terminal asal dan terminal tujuan. Setiap peran direpresentasikan oleh foreign key yang berbeda pada fact table meskipun mengarah ke dimension table yang sama.

Junk Dimensions

`dim_sales_context` digunakan sebagai junk dimension untuk menggabungkan atribut transaksi dengan kardinalitas rendah, seperti kelas tarif, kanal pemesanan, metode pembayaran, dan penanda tiket dapat dikembalikan. Penggabungan ini menghindari pembuatan beberapa dimension table kecil yang hanya memiliki sedikit atribut.

Outrigger Dimensions

Rancangan awal tidak menggunakan outrigger dimension. Atribut deskriptif disimpan langsung pada dimensi terkait agar bentuk star schema tetap sederhana. Keputusan ini dapat ditinjau kembali apabila ditemukan hierarki yang perlu dikelola secara terpisah pada tahap implementasi.

1.3.5 Slowly Changing Dimensions

Atribut yang Berubah

Atribut yang diperkirakan berubah meliputi tingkat loyalitas dan data kontak penumpang, kelas serta konfigurasi kursi armada, dan kapasitas terminal. Perubahan tersebut perlu dibedakan antara perubahan yang memengaruhi analisis historis dan koreksi administratif.

Strategi SCD dan Justifikasi

- `dim_passenger.loyalty_tier` menggunakan SCD Tipe 2 agar tingkat loyalitas pada saat transaksi tetap dapat diketahui. Setiap perubahan membuat versi baris baru.
- `dim_passenger.email` dan `phone` menggunakan SCD Tipe 1 karena perubahan data kontak diperlukan sebagai pembaruan administratif.
- `dim_bus_fleet.bus_class`, `seat_configuration`, dan `seat_capacity` menggunakan SCD Tipe 2 agar kapasitas dan kelas armada pada perjalanan historis tetap dapat dianalisis dengan benar.
- Koreksi salah ketik pada `dim_bus_fleet.license_plate` menggunakan SCD Tipe 1. Perubahan pelat yang benar-benar terjadi secara operasional diperlukan sebagai perubahan historis.
- `dim_terminal.capacity_per_day` menggunakan SCD Tipe 2 jika perubahan kapasitas diperlukan dalam analisis historis, sedangkan koreksi nama terminal menggunakan SCD Tipe 1.


Dimensi yang menggunakan SCD Tipe 2 akan memiliki surrogate key, natural key, `effective_start_date`, `effective_end_date`, dan `is_current`. Kombinasi kolom tersebut digunakan untuk menentukan versi dimensi yang berlaku pada tanggal suatu transaksi.



1.3.6 Diagram Skema Dimensional

Star Schema atau Snowflake Schema

Rancangan menggunakan pendekatan star schema dengan tiga fact table yang berbagi conformed dimensions. Keseluruhan rancangan dapat dipandang sebagai kumpulan tiga star schema yang saling berhubungan melalui `dim_passenger`, `dim_date`, dan `dim_time`. Selain itu, `dim_route` digunakan bersama oleh fact penjualan tiket dan fact perjalanan penumpang. Hubungan antartabel pada tingkat konseptual ditunjukkan pada Gambar 1.1. Versi ini hanya menampilkan fact table, dimension table, dan hubungan antartabel agar struktur keseluruhan lebih mudah dibaca.



Gambar 1.1: Fact constellation perjalanan bus antarkota multi-leg dan loyalitas penumpang pada tingkat konseptual

Relasi dan Tipe Data Utama

Rincian kolom dan tipe data ditunjukkan pada Gambar 1.2. Diagram tersebut mencantumkan primary key, foreign key, dan tipe data utama pada setiap tabel. Surrogate key menggunakan tipe integer, nilai finansial menggunakan decimal, jumlah poin dan durasi menggunakan integer, sedangkan tanggal dan waktu dihubungkan melalui pasangan date key dan time key. Dimensi tanggal, waktu, penumpang, dan rute digunakan oleh lebih dari satu fact table sebagai conformed dimensions.


1.4 SYNTHETIC DATA GENERATION

1.4.1 Strategi Pembuatan Data Sintetis

Data sumber dibuat dengan skrip Python pada berkas `synthetic-data-generation/generate.py`. Pustaka Faker digunakan untuk membuat identitas penumpang, sedangkan nilai transaksi, jadwal, keterlambatan, dan mutasi poin dibuat dengan generator kustom. Data yang dihasilkan merupakan data operasional mentah. Surrogate key dan struktur fact-dimension belum diterapkan pada tahap ini.

Generator menggunakan `SEED = 2026`. Seed tersebut membuat hasil pembangkitan dapat diulang dengan isi yang sama. Hasil disimpan pada direktori `data/raw`. Jika direktori tersebut sudah berisi file, proses pembangkitan dilewati agar data yang telah digunakan tidak tertimpa.

Perjalanan dibuat dalam satu sampai tiga leg. Setiap leg berikutnya dimulai dari terminal tujuan leg



Gambar 1.2: Fact constellation beserta kolom dan tipe data utama

sebelumnya. Jadwal bus digunakan oleh beberapa penumpang dan jumlah tiket pada satu trip dibatasi oleh kapasitas armada. Juni, Juli, dan Desember diberi peluang perjalanan yang lebih besar untuk mewakili musim sibuk.

1.4.2 Kode Generator

Nilai acak tidak semuanya menggunakan peluang yang sama. Tingkat loyalitas, kanal pemesanan, kelas bus, promosi, dan metode pembayaran menggunakan bobot yang berbeda. Tarif dihitung dari jarak rute, kelas bus, dan penanda musim sibuk. Keterlambatan normal dibuat dengan distribusi Gaussian, kemudian sebagian trip diberi keterlambatan ekstrem sebagai outlier.

Bagian berikut menunjukkan konfigurasi utama dan pemeriksaan direktori keluaran.

SEED = 2026

TOTAL_PASSENGERS = 4_000

TOTAL_TICKET_LEGS = 25_000

PEAK_MONTHS = {6, 7, 12}

```
def main():
    if OUTPUT_DIR.exists() and any(OUTPUT_DIR.iterdir()):
        print("Data mentah sudah tersedia.")
        print("Proses generate dilewati agar file tidak tertimpa.")
        return
```

Sebelum CSV ditulis, fungsi `validate()` memeriksa foreign key alami, urutan terminal pada itinerary, kapasitas bus, tanggal registrasi dan pemesanan, serta saldo transaksi loyalitas. Generator juga membuat



manifest.json yang berisi jumlah baris dan checksum SHA-256 setiap CSV.

Hasil pembangkitan terdiri atas 96.447 baris dalam 15 CSV dengan ukuran sekitar 7,8 MB. Rincian jumlah baris ditunjukkan pada Tabel 1.2.

Tabel 1.2: Jumlah Baris Data Mentah

Berkas	Baris	Berkas	Baris
raw_passengers	4.000	raw_bookings	12.510
raw_passenger_tier_history	4.941	raw_ticket_legs	25.000
raw_terminals	25	raw_trip_events	4.018
raw_routes	30	raw_passenger_leg_events	25.000
raw_bus_fleets	80	raw_loyalty_transactions	13.928
raw_bus_fleet_history	24	raw_compensation_claims	2.860
raw_terminal_capacity_history	10	raw_promotions	3
raw_bus_schedules	4.018		

Sebanyak 25.000 tiket-leg berasal dari 12.510 itinerary dan menggunakan 4.018 trip terjadwal. Rata-rata terdapat 6,22 penumpang per trip. Hasil pemeriksaan menunjukkan bahwa tidak ada jumlah penumpang yang melebihi kapasitas armada. Sekitar 49,5% keberangkatan leg pertama terjadi pada bulan musim sibuk. Angka ini muncul dari bobot tanggal perjalanan yang lebih besar pada Juni, Juli, dan Desember.

Data memuat 50 pelanggan tanpa alamat email. Nilai kosong tersebut sengaja dipertahankan untuk menguji penanganan missing value pada proses ETL. Selain itu, terdapat 104 trip dengan keterlambatan kedatangan di atas 120 menit. Gangguan dibagi menjadi kerusakan mesin, kemacetan, dan cuaca.

Gagal koneksi ditentukan dengan membandingkan kedatangan aktual leg sebelumnya dan keberangkatan aktual leg lanjutan. Jika waktu yang tersisa kurang dari 15 menit, penumpang diberi status MISSED_CONNECTION. Dataset memuat 2.860 kejadian tersebut dan setiap kejadian memiliki satu catatan klaim.

Skenario SCD Tipe 2 tersedia pada riwayat tingkat loyalitas penumpang, perubahan kelas atau kapasitas armada, dan perubahan kapasitas terminal. Setiap baris riwayat memiliki natural key, effective_start_date, dan effective_end_date. Nilai tanggal akhir dikosongkan untuk versi yang masih berlaku.

1.4.3 Contoh Data Mentah

Contoh berikut menunjukkan satu itinerary dengan dua leg. Tujuan leg pertama, TRM-10, menjadi terminal asal leg kedua.

Tabel 1.3: Contoh Baris pada raw_ticket_legs

Tiket	Itinerary	Leg	Asal	Tujuan	Pendapatan
TICK-000001	ITI-000001	1	TRM-09	TRM-10	183.000
TICK-000002	ITI-000001	2	TRM-10	TRM-11	205.000

Pada tabel jadwal, kedua tiket tersebut merujuk pada TRIP-000001 dan TRIP-000002. Waktu terjadwal dan waktu aktual disimpan pada tabel yang berbeda sehingga keterlambatan dapat dihitung tanpa mengubah data jadwal. Pemisahan serupa digunakan untuk booking, transaksi loyalitas, dan klaim kompensasi.

1.4.4 Skema Sumber

Generator menghasilkan 15 berkas CSV. Berkas tersebut dikelompokkan berdasarkan proses sumber pada Tabel 1.4.



Tabel 1.4: Kelompok Data Sumber Sintetis

Kelompok	Berkas	Kegunaan pada Data Mart
Pelanggan	raw_passengers, raw_passenger_tier_history	Sumber dim_passenger dan riwayat tingkat loyalitas
Referensi perjalanan	raw_terminals, raw_routes, raw_bus_fleets	Sumber dimensi terminal, rute, dan armada
Riwayat referensi	raw_bus_fleet_history, raw_terminal_capacity_history	Skenario perubahan kelas armada dan kapasitas terminal
Jadwal	raw_bus_schedules	Sumber trip, armada, rute, dan waktu terjadwal
Penjualan tiket	raw_bookings, raw_ticket_legs, raw_promotions	Sumber fct_ticket_sales dan konteks penjualan
Pelaksanaan perjalanan	raw_trip_events, raw_passenger_leg_events	Sumber waktu aktual, keterlambatan, dan status perjalanan penumpang
Loyalitas	raw_loyalty_transactions	Sumber fct_loyalty_transaction
Klaim	raw_compensation_claims	Sumber nilai refund, kompensasi, dan rebooking

Relasi antarsumber masih menggunakan natural key, misalnya `passenger_id`, `booking_id`, `ticket_number`, `trip_id`, dan `route_id`. Surrogate key baru dibuat pada proses ETL ketika dimension table dan fact table dibangun.

1.5 DATA MART

1.5.1 Skema Final Data Mart

Pipeline ETL diimplementasikan pada `data-mart/etl.py`. Skrip tersebut membaca seluruh CSV pada `synthetic-data-generation/data/raw`, membentuk surrogate key, menentukan versi dimensi SCD yang berlaku pada tanggal kejadian, dan menulis hasil akhir sebagai CSV. Keluaran dipisahkan ke dalam direktori `dimensions`, `facts`, dan `rejected`.

Data mart menggunakan fact constellation yang terdiri atas tiga fact table dan sepuluh dimension table. Jumlah baris setiap tabel ditunjukkan pada Tabel 1.5.

Tabel 1.5: Tabel Final Data Mart

Tabel	Baris	Tabel	Baris
dim_date	385	dim_sales_context	48
dim_time	1.440	dim_promotion	4
dim_passenger	4.941	dim_disruption_reason	7
dim_terminal	30	dim_loyalty_transaction_type	2
dim_route	30	fct_ticket_sales	25.000
dim_bus_fleet	92	fct_passenger_itinerary_leg	24.980
		fct_loyalty_transaction	13.928

`dim_passenger`, `dim_bus_fleet`, dan `dim_terminal` menerapkan SCD Tipe 2. Foreign key pada fact table ditentukan dengan pencarian versi dimensi berdasarkan tanggal transaksi atau perjalanan. Dengan cara ini, perubahan tingkat loyalitas, kelas armada, dan kapasitas terminal tidak mengubah hasil analisis periode sebelumnya.



1.5.2 Dokumentasi Tabel dan Kolom

Dokumentasi tipe data, primary key, dan foreign key tersedia pada `data-mart/schema.sql`. Deskripsi setiap tabel dan kolom tersedia pada `data-mart/data_dictionary.csv`. Ringkasan grain dan kolom utama fact table adalah sebagai berikut:

Tabel 1.6: Grain dan Kolom Utama Fact Table Final

Fact table	Grain	Kolom utama
<code>fct_ticket_sales</code>	Satu tiket penumpang pada satu itinerary leg	Surrogate key penumpang, tanggal, waktu, rute, konteks penjualan, promosi, tarif, diskon, pajak, pendapatan, dan poin
<code>fct_passenger_itinerary_leg</code>	Satu penumpang pada satu leg dalam satu trip terjadwal	Surrogate key penumpang, rute, armada, terminal, waktu terjadwal dan aktual, delay, gagal koneksi, refund, rebooking, dan kompensasi
<code>fct_loyalty_transaction</code>	Satu mutasi poin milik satu penumpang	Surrogate key penumpang, tanggal, waktu, jenis transaksi, perubahan poin, dan saldo setelah transaksi

Pada tahap validasi ditemukan tiga trip yang jumlah tiketnya melebihi kapasitas armada berdasarkan versi SCD yang berlaku. Raw data tidak diubah. ETL mengurutkan tiket berdasarkan waktu pemesanan, memuat penumpang sampai batas kapasitas, dan menempatkan sisanya pada `rejected_itinerary_legs.csv` dengan alasan `TRIP_CAPACITY_EXCEEDED`.

Sebanyak 20 baris masuk karantina. Rekonsiliasinya adalah 25.000 baris sumber, 24.980 baris dimuat ke `fct_passenger_itinerary_leg`, dan 20 baris disimpan sebagai rejected record. Seluruh 25.000 transaksi tetap dimuat ke `fct_ticket_sales` karena transaksi penjualannya tetap terjadi. Satu tiket karantina mempunyai klaim berstatus approved. ID klaim dan nilai refund, kompensasi, serta rebooking tetap disimpan pada file karantina, tetapi tidak dimasukkan dalam perhitungan measure pada fact perjalanan. Pemeriksaan setelah ETL tidak menemukan orphan foreign key pada ketiga fact table. Jumlah baris dan checksum setiap keluaran dicatat pada `data-mart/output/manifest.json`.

1.5.3 Koneksi ke BI Tools

Keluaran data mart berupa CSV agar dapat digunakan tanpa bergantung pada satu database. Pada Tableau, setiap fact table dapat dijadikan pusat satu data source, kemudian dihubungkan dengan dimension table menggunakan kolom surrogate key berakhiran `_sk`. Relationship digunakan agar grain setiap tabel tetap dipertahankan.

CSV yang sama dapat digunakan pada visualisasi berbasis Python dengan pandas. Dengan demikian, Tableau dan Python membaca hasil ETL yang sama. Implementasi koneksi dan dashboard dibahas pada Bab 2.

1.5.4 Semantic Layer

Belum ada semantic layer yang disimpan sebagai komponen terpisah. Definisi metrik bisnis diterapkan secara konsisten pada query verifikasi dan alat visualisasi. Metrik tersebut meliputi pendapatan tiket, missed connection rate, SLA breach rate, dan revenue leakage.



1.6 VERIFIKASI DAN VALIDASI

1.6.1 Query Analitik

Verifikasi dilakukan melalui notebook `verification.ipynb`. CSV hasil ETL dimuat ke SQLite in-memory menggunakan `pandas`, kemudian query dijalankan dengan `read_sql_query()`. SQLite hanya digunakan selama notebook berjalan dan tidak menjadi format penyimpanan data mart.

Lima query berikut dibuat untuk menjawab business questions pada Bagian 1.2.3.

Terminal Transit dan Pasangan Route

Query pertama memasang leg dengan leg sebelumnya berdasarkan itinerary dan urutan leg. Terminal asal pada leg lanjutan diperlakukan sebagai terminal transit.

```
SELECT
    t.terminal_name AS transit_terminal ,
    route_in.route_name AS incoming_route ,
    route_out.route_name AS onward_route ,
    COUNT(*) AS total_connection_legs ,
    SUM(f.missed_connection_count) AS total_missed_connections ,
    ROUND(100.0 * SUM(f.missed_connection_count) / COUNT(*) , 2)
    AS missed_connection_rate_pct
FROM fct_passenger_itinerary_leg AS f
JOIN fct_passenger_itinerary_leg AS previous_leg
    ON f.itinerary_id = previous_leg.itinerary_id
    AND f.leg_sequence = previous_leg.leg_sequence + 1
JOIN dim_terminal AS t ON f.origin_terminal_sk = t.terminal_sk
JOIN dim_route AS route_in ON previous_leg.route_sk = route_in.route_sk
JOIN dim_route AS route_out ON f.route_sk = route_out.route_sk
GROUP BY t.terminal_name , route_in.route_name , route_out.route_name
HAVING COUNT(*) >= 10
ORDER BY missed_connection_rate_pct DESC
LIMIT 10;
```

Keterlambatan dan Pelanggaran SLA

Keterlambatan diringkas lebih dahulu per trip agar satu perjalanan bus tidak dihitung berulang untuk setiap penumpang. Batas pelanggaran SLA ditetapkan pada arrival delay di atas 60 menit.

```
WITH trip_performance AS (
    SELECT DISTINCT
        trip_id , route_sk , bus_fleet_sk , arrival_delay_minutes
    FROM fct_passenger_itinerary_leg
)
SELECT
    r.route_name ,
    b.bus_fleet_id ,
    b.bus_class ,
    COUNT(*) AS total_trips ,
    ROUND(AVG(tp.arrival_delay_minutes) , 2)
    AS avg_arrival_delay_minutes ,
    ROUND(100.0 * SUM(
```



```

        CASE WHEN tp.arrival_delay_minutes > 60 THEN 1 ELSE 0 END
    ) / COUNT(*), 2) AS sla_breach_rate_pct
FROM trip_performance AS tp
JOIN dim_route AS r ON tp.route_sk = r.route_sk
JOIN dim_bus_fleet AS b ON tp.bus_fleet_sk = b.bus_fleet_sk
GROUP BY r.route_name, b.bus_fleet_id, b.bus_class
HAVING COUNT(*) >= 3
ORDER BY sla_breach_rate_pct DESC, avg_arrival_delay_minutes DESC
LIMIT 10;

```

Revenue Leakage pada Musim Sibuk

Revenue leakage dihitung dari refund, biaya rebooking, dan kompensasi pada klaim berstatus approved. Baris karantina tidak dimasukkan ke perhitungan fact.

```

SELECT
    r.route_name,
    SUM(f.refund_amount) AS total_refund,
    SUM(f.rebooking_cost) AS total_rebooking_cost,
    SUM(f.compensation_amount) AS total_compensation,
    SUM(f.refund_amount + f.rebooking_cost + f.compensation_amount)
    AS total_revenue_leakage
FROM fct_passenger_itinerary_leg AS f
JOIN dim_route AS r ON f.route_sk = r.route_sk
JOIN dim_date AS d ON f.scheduled_departure_date_sk = d.date_sk
WHERE d.is_peak_season = 1
    AND f.claim_status = 'Approved'
GROUP BY r.route_name
ORDER BY total_revenue_leakage DESC
LIMIT 10;

```

Perbandingan Berdasarkan Loyalty Tier

Query keempat membandingkan frekuensi booking, pendapatan kotor tiket, dan mutasi poin berdasarkan tier yang berlaku pada saat transaksi.

```

SELECT
    p.loyalty_tier,
    COUNT(DISTINCT f.itinerary_id) AS total_bookings,
    COUNT(DISTINCT p.passenger_id) AS total_passengers,
    ROUND(1.0 * COUNT(DISTINCT f.itinerary_id)
        / COUNT(DISTINCT p.passenger_id), 2) AS avg_booking_frequency,
    ROUND(AVG(f.allocated_base_fare - f.discount_amount), 2)
    AS avg_gross_ticket_revenue,
    SUM(f.loyalty_points_earned) AS total_points_earned,
    SUM(f.loyalty_points_redeemed) AS total_points_redeemed
FROM fct_ticket_sales AS f
JOIN dim_passenger AS p ON f.passenger_sk = p.passenger_sk
GROUP BY p.loyalty_tier
ORDER BY avg_booking_frequency DESC;

```



Missed Connection dan Repeat Booking

Query terakhir membentuk ringkasan gangguan dan jumlah booking per penumpang. Natural key `passenger_id` digunakan agar beberapa versi SCD milik orang yang sama tetap dihitung bersama.

```
WITH disruption_by_passenger AS (
    SELECT
        p.passenger_id,
        MAX(f.missed_connection_count) AS ever_missed_connection
    FROM fct_passenger_itinerary_leg AS f
    JOIN dim_passenger AS p ON f.passenger_sk = p.passenger_sk
    GROUP BY p.passenger_id
),
booking_by_passenger AS (
    SELECT
        p.passenger_id,
        COUNT(DISTINCT f.booking_id) AS booking_count
    FROM fct_ticket_sales AS f
    JOIN dim_passenger AS p ON f.passenger_sk = p.passenger_sk
    GROUP BY p.passenger_id
)
SELECT
    CASE WHEN d.ever_missed_connection = 1
        THEN 'Pernah■missed■connection'
        ELSE 'Tidak■pernah■missed■connection'
    END AS disruption_group,
    COUNT(*) AS passenger_count,
    ROUND(AVG(b.booking_count), 2) AS avg_booking_count,
    ROUND(100.0 * AVG(
        CASE WHEN b.booking_count > 1 THEN 1.0 ELSE 0.0 END
    ), 2) AS repeat_booking_rate_pct
FROM disruption_by_passenger AS d
JOIN booking_by_passenger AS b ON d.passenger_id = b.passenger_id
GROUP BY d.ever_missed_connection
ORDER BY d.ever_missed_connection DESC;
```

1.6.2 Hasil Query

Hasil Query Terminal Transit dan Pasangan Rute

Lima pasangan rute dengan missed connection rate tertinggi ditunjukkan pada Tabel 1.7.

Tabel 1.7: Hasil Query Missed Connection per Terminal dan Pasangan Rute

Terminal	Rute masuk	Rute lanjutan	Koneksi	Rate (%)
Pati	Cilacap–Pati	Pati–Jakarta	285	95,79
Salatiga	Magelang–Salatiga	Salatiga–Jepara	550	93,45
Pekalongan	Cilacap–Pekalongan	Pekalongan–Magelang	303	88,12
Surabaya	Yogyakarta–Surabaya	Surabaya–Purwokerto	222	86,94
Banyuwangi	Probolinggo–Banyuwangi	Banyuwangi–Cilacap	241	84,23

Terminal Pati menempati urutan pertama dengan 273 missed connection dari 285 leg koneksi. Nilai yang tinggi menunjukkan bahwa kombinasi jadwal dan delay pada pasangan rute tersebut menyediakan waktu transit yang terlalu sempit dalam data sintetis. Hasil ini tidak dapat digeneralisasi ke operator bus nyata.



Hasil Query Keterlambatan dan Pelanggaran SLA

Tabel 1.8: Hasil Query Arrival Delay dan SLA Breach

Rute	Armada	Kelas	Trip	Delay	SLA (%)
Jakarta–Surabaya	BUS-071	Executive	3	115,33	66,67
Kediri–Madiun	BUS-059	Executive	3	67,67	66,67
Sukabumi–Tasikmalaya	BUS-058	Economy	3	63,67	66,67
Tasikmalaya–Garut	BUS-038	Executive	3	62,00	66,67
Cirebon–Tegal	BUS-017	Economy	4	105,00	50,00

Kombinasi Jakarta–Surabaya dan BUS-071 memiliki rata-rata arrival delay tertinggi pada hasil lima besar. Jumlah trip per kombinasi masih kecil sehingga hasil ini lebih tepat digunakan sebagai indikator untuk pemeriksaan lebih lanjut.

Hasil Query Revenue Leakage

Tabel 1.9: Revenue Leakage pada Musim Sibuk

Rute	Refund	Rebooking	Kompensasi	Total
Salatiga–Jepara	25.564.000	16.464.000	14.625.000	56.653.000
Tegal–Purwokerto	22.446.000	14.507.000	12.625.000	49.578.000
Pati–Jakarta	21.594.000	14.090.000	8.600.000	44.284.000
Surabaya–Malang	16.696.000	10.728.000	5.475.000	32.899.000
Banyuwangi–Cilacap	15.148.000	9.748.000	6.350.000	31.246.000

Rute Salatiga–Jepara mencatat revenue leakage terbesar pada musim sibuk dalam data mart. Nilai ini berasal dari penjumlahan tiga komponen biaya pada klaim approved dan belum memasukkan satu klaim yang berada pada file karantina.

Hasil Query Berdasarkan Loyalty Tier

Tabel 1.10: Perbandingan Aktivitas Berdasarkan Loyalty Tier

Tier	Booking	Penumpang	Frekuensi	Avg. Revenue	Earned	Redeemed
Basic	8.254	2.749	3,00	196.054,71	357.627	17.800
Platinum	909	314	2,89	200.506,25	40.957	2.090
Gold	3.347	1.275	2,63	197.551,65	146.961	7.790

Tier Basic memiliki jumlah booking dan penumpang terbesar karena proporsinya memang paling besar pada generator. Pendapatan kotor rata-rata per leg tertinggi terdapat pada tier Platinum, sedangkan rata-rata frekuensi booking antartier berada pada rentang 2,63 sampai 3,00.

Hasil Query Missed Connection dan Repeat Booking

Pada dataset sintetis, penumpang yang pernah mengalami missed connection justru memiliki repeat booking rate lebih tinggi. Hasil tersebut tidak mendukung dugaan asosiasi negatif pada business question. Salah satu kemungkinan penjelasan adalah exposure: penumpang dengan lebih banyak booking memiliki lebih banyak kesempatan mengalami gangguan. Analisis ini bersifat deskriptif dan tidak menunjukkan hubungan sebab-akibat.

1.6.3 Data Quality Check

Pemeriksaan kualitas mencakup duplikasi surrogate key, orphan foreign key, unexpected null pada kolom wajib, saldo loyalitas negatif, kapasitas historis, versi aktif SCD, dan rekonsiliasi baris karantina.

Seluruh pemeriksaan menghasilkan nol masalah. Hal ini berlaku setelah 20 baris yang melampaui kapasitas



Tabel 1.11: Perbandingan Repeat Booking Berdasarkan Riwayat Gangguan

Kelompok	Penumpang	Avg. Booking	Repeat Rate (%)
Pernah missed connection	2.021	3,82	94,85
Tidak pernah missed connection	1.790	2,68	76,54

Tabel 1.12: Hasil Data Quality Check

Pemeriksaan	Jumlah masalah
Duplicate ticket_sales_sk	0
Duplicate itinerary_leg_sk	0
Duplicate loyalty_transaction_sk	0
Orphan foreign key pada fact penjualan	0
Orphan foreign key pada fact perjalanan	0
Orphan foreign key pada fact loyalitas	0
Saldo loyalitas negatif	0
Unexpected null pada kolom wajib fact	0
Trip melebihi kapasitas historis	0
Lebih dari satu versi penumpang aktif	0
Selisih rekonsiliasi itinerary	0

dipisahkan ke file karantina. Rekonsiliasi tetap dapat dilacak karena 24.980 baris fact perjalanan ditambah 20 baris karantina sama dengan 25.000 baris sumber.

1.7 KESIMPULAN DAN REFLEKSI

1.7.1 Kesimpulan

Proyek ini menghasilkan data mart untuk tiga proses bisnis, yaitu penjualan tiket, pelaksanaan perjalanan per leg, dan transaksi loyalitas. Ketiga fact table menggunakan dimensi bersama sehingga transaksi dapat dianalisis berdasarkan penumpang, tanggal, rute, terminal, dan armada yang konsisten. Lima query dapat dijalankan terhadap hasil ETL dan seluruh data quality check menghasilkan nol masalah setelah proses karantina diterapkan.

Hasil query memperlihatkan pasangan rute dengan missed connection tinggi, variasi delay dan pelanggaran SLA antarm armada, serta perbedaan revenue leakage pada musim sibuk. Perbandingan loyalitas tidak menunjukkan asosiasi negatif antara missed connection dan repeat booking pada data sintetis. Temuan tersebut perlu dibaca sebagai karakteristik dataset yang dibangkitkan, bukan gambaran operator nyata.

1.7.2 Tantangan yang Dihadapi

Tantangan pertama adalah menjaga grain ketika delay pada satu trip muncul pada banyak baris penumpang. Query operasional harus meringkas data per trip sebelum menghitung rata-rata delay. Tantangan kedua adalah memilih versi dimensi SCD yang berlaku pada tanggal transaksi. Fact table tidak cukup dihubungkan ke versi dimensi terkini karena cara tersebut akan mengubah konteks historis.

Validasi juga menemukan tiga trip yang melampaui kapasitas armada historis. Masalah tersebut tidak diselesaikan dengan mengubah raw data. Sebanyak 20 baris dipisahkan ke karantina dan tetap disertakan dalam rekonsiliasi. Pendekatan ini menjaga jejak antara data sumber, baris yang dimuat, dan baris yang ditolak.



1.7.3 Keputusan Desain Utama

Tiga keputusan desain yang digunakan adalah memisahkan proses bisnis ke dalam tiga fact table, mempertahankan grain atomik per tiket-leg, dan menerapkan SCD Tipe 2 pada atribut yang memerlukan histori. Data mart disimpan sebagai CSV agar tidak bergantung pada database tertentu. `schema.sql` digunakan untuk mendokumentasikan struktur dan SQLite in-memory digunakan hanya untuk verifikasi query.

1.7.4 Kesiapan Data Mart untuk Visualisasi

CSV fact dan dimension table dapat dibaca langsung oleh Tableau dan pandas. Surrogate key telah tersedia untuk membentuk relationship antara fact dan dimension table. Data dictionary juga mencatat tipe dan arti setiap kolom. Data mart tersebut telah digunakan sebagai sumber dashboard Tableau dan Python yang dibahas pada Bab 2.

1.8 REFERENSI

1. Kimball, R. dan Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, edisi ketiga. Wiley.
2. Mustofa, K. (2026). *Pengantar Warehouse; Pengembangan Data Warehouse; dan Extract, Transform, and Load*. Materi perkuliahan Data Warehouse & Business Intelligence.
3. Python Software Foundation. *Python Documentation*: <https://docs.python.org/3/>.
4. pandas development team. *pandas Documentation*: <https://pandas.pydata.org/docs/>.
5. Faker contributors. *Faker Documentation*: <https://faker.readthedocs.io/>.
6. SQLite Consortium. *SQLite Documentation*: <https://www.sqlite.org/docs.html>.



BAB 2

Visualisasi

Anggota Kelompok

1. Citra Putri Saragih (25/574147/PPA/07239)
2. Ade Dwi Putra (25/574144/PPA/07237)

2.1 SKENARIO DAN PENGGUNA DASHBOARD

Visualisasi dibangun di atas data mart perjalanan bus antarkota yang telah dihasilkan pada Bab 1. Pengguna dashboard terdiri atas VP of Operations, VP Commercial and Revenue Management, serta Head of Customer Loyalty. Bagian operasional membutuhkan informasi keterlambatan, pelanggaran SLA, dan kegagalan koneksi. Bagian komersial menggunakan informasi kerugian akibat gangguan perjalanan, sedangkan bagian loyalitas memantau pola transaksi dan penggunaan poin penumpang.

Data yang ditampilkan bersifat sintesis. Hasil visualisasi digunakan untuk menunjukkan kemampuan data mart dalam menjawab kebutuhan analitik dan tidak dimaksudkan untuk menggambarkan kondisi operator bus tertentu.

2.2 TOOLS VISUALISASI

2.2.1 Tableau

Tableau digunakan untuk membentuk relationship antara fact table dan dimension table, membuat calculated field, serta menyusun dashboard interaktif. Tiga dashboard dibuat dalam satu workbook untuk memisahkan analisis operasional, penjualan tiket, dan transaksi loyalitas.

2.2.2 Python-based Tools

Tool kedua menggunakan pandas, Plotly, dan Streamlit. Pandas digunakan untuk membaca serta menggabungkan keluaran data mart, Plotly untuk membentuk grafik, dan Streamlit sebagai antarmuka dashboard. Implementasinya ditempatkan dalam satu berkas `dashboard.py`.

Kedua tools membaca berkas CSV pada direktori `data-mart/output`. Tidak ada dataset baru yang dibangkitkan pada tahap visualisasi. Workbook Tableau disimpan dalam format `.twbx` agar worksheet, relationship, dan sumber data berada dalam satu berkas.



2.3 PERANCANGAN DASHBOARD

Dashboard Tableau dibagi menjadi tiga bagian berdasarkan proses bisnis:

- Kinerja Operasional dan Dampak Finansial**, untuk menganalisis arrival delay, status SLA, missed connection, dan revenue leakage;
- Loyalitas dan Perilaku Penumpang**, untuk membandingkan jumlah tiket, pendapatan rata-rata, dan penggunaan poin pada setiap loyalty tier; dan
- Aktivitas Transaksi Loyalitas**, untuk melihat jumlah transaksi, mutasi poin, serta perubahan aktivitas loyalitas setiap bulan.

Pembagian tersebut mengikuti tiga fact table pada data mart sehingga measure dengan grain berbeda tidak digabungkan secara langsung dalam satu tabel datar.

2.3.1 Definisi Metrik

- Missed connection rate* adalah jumlah `missed_connection_count` dibagi jumlah itinerary leg yang diamati.
- Status *SLA breach* diberikan pada perjalanan dengan `arrival_delay_minutes` lebih dari 60 menit.
- Revenue leakage* merupakan jumlah `rebooking_cost`, `refund_amount`, dan `compensation_amount` pada klaim yang disetujui selama peak season.
- Aktivitas poin dibedakan menjadi EARN sebagai poin masuk dan REDEEM sebagai poin keluar.

2.4 IMPLEMENTASI PYTHON-BASED TOOLS

Program membaca tiga fact table dan dimension table yang relevan. Penggabungan dilakukan melalui surrogate key yang telah dibentuk oleh ETL, kemudian hasil agregasi disiapkan untuk ditampilkan melalui antarmuka Streamlit.


Dashboard menyediakan lima kelompok analisis yang mengikuti business questions, yaitu missed connection, delay dan SLA, revenue leakage, perbandingan loyalty tier, serta repeat booking. Pada analisis armada, data diringkas menjadi satu baris per `trip_id` terlebih dahulu karena grain fact perjalanan berada pada tingkat penumpang-leg. Dengan cara ini, satu keterlambatan bus tidak dihitung berulang untuk seluruh penumpang dalam perjalanan yang sama.

Tabel hasil agregasi disediakan bersama grafik agar angkanya dapat dibandingkan dengan query verifikasi pada Bab 1.6. Analisis repeat booking diperlakukan sebagai asosiasi, bukan hubungan sebab-akibat, karena data tidak mengendalikan seluruh faktor yang dapat memengaruhi perilaku pemesanan penumpang.


2.4.1 Hasil Dashboard Python

Gambar 2.1 menunjukkan pasangan Cilacap–Pati dan Pati–Jakarta sebagai koneksi dengan missed connection rate tertinggi, yaitu 95,79 persen dari 285 koneksi. Urutan hasilnya sama dengan query pertama pada Bab 1.6.


Visual delay dan SLA pada Gambar 2.2 menggunakan satu observasi per trip. Kombinasi Jakarta–Surabaya dan BUS-071 memiliki rata-rata delay 115,33 menit dengan SLA breach rate 66,67 persen dari tiga perjalanan.



Gambar 2.1: Analisis missed connection menggunakan Python



Gambar 2.2: Analisis arrival delay dan SLA menggunakan Python



Gambar 2.3: Analisis revenue leakage menggunakan Python



Gambar 2.3 memperlihatkan rute Salatiga–Jepara sebagai rute dengan revenue leakage tertinggi pada peak season, yaitu Rp56.653.000. Nilai tersebut berasal dari refund, biaya rebooking, dan kompensasi pada klaim yang disetujui.



Gambar 2.4: Perbandingan aktivitas berdasarkan loyalty tier menggunakan Python

Perbandingan pada Gambar 2.4 menunjukkan bahwa Basic memiliki jumlah booking dan penumpang terbesar, sementara pendapatan rata-rata tertinggi terdapat pada Platinum. Grafik poin juga memperlihatkan bahwa perolehan poin lebih dominan daripada penukarannya pada seluruh tier.


Gambar 2.5 memperlihatkan repeat booking rate sebesar 94,85 persen pada penumpang yang pernah mengalami missed connection dan 76,54 persen pada kelompok tanpa missed connection. Hasil ini menunjukkan asosiasi pada data sintetis, bukan hubungan sebab-akibat.

2.5 HASIL IMPLEMENTASI TABLEAU

2.5.1 Konfigurasi Data Source

Tiga data source dibentuk dengan menempatkan satu fact table sebagai tabel pusat. Data source operasional menggunakan `fact_passenger_itinerary_leg`, data source penjualan menggunakan `fact_ticket_sales`, dan data source transaksi loyalitas menggunakan `fact_loyalty_transaction`. Dimension table dihubungkan menggunakan relationship berdasarkan surrogate key berakhiran `_sk`.


Pemisahan tersebut mempertahankan grain masing-masing fact table dan mengurangi risiko fan-out. Dimension table yang digunakan bersama, seperti `dim_passenger`, `dim_date`, dan `dim_route`, tetap berperan sebagai conformed dimensions. Calculated field yang digunakan meliputi SLA Status, Connection Leg, Missed Connection Rate, dan Revenue Leakage.




Gambar 2.5: Perbandingan repeat booking berdasarkan riwayat gangguan

Dashboard Kinerja Operasional dan Dampak Finansial


Sebaran Arrival Delay dan Status SLA per Trip dan Rute



Missed Connection Rate per Terminal Transit



Revenue Leakage per Rute pada Peak Season



Gambar 2.6: Dashboard kinerja operasional dan dampak finansial



2.5.2 Dashboard Kinerja Operasional dan Dampak Finansial

Gambar 2.6 memperlihatkan sebaran arrival delay pada setiap rute. Titik merah menunjukkan keterlambatan di atas batas SLA 60 menit, sedangkan titik hijau masih berada dalam SLA. Beberapa perjalanan memiliki delay lebih dari 200 menit sehingga terlihat sebagai outlier operasional.

Terminal Salatiga memiliki missed connection rate tertinggi, yaitu 93,45 persen, disusul Terminal Pekalongan sebesar 88,12 persen dan Terminal Tegal sebesar 81,84 persen. Pada peak season, rute Salatiga–Jepara mencatat revenue leakage terbesar sebesar Rp56.653.000, kemudian Tegal–Purwokerto sebesar Rp49.578.000 dan Pati–Jakarta sebesar Rp44.284.000. Filter rute dapat digunakan untuk mempersempit analisis ke rute tertentu.


2.5.3 Dashboard Loyalitas dan Perilaku Penumpang

Loyalitas dan Perilaku Penumpang


Jumlah Tiket per Loyalty Tier



Rata-rata Pendapatan per Loyalty Tier



Rata-rata Poin Loyalitas per Transaksi



Gambar 2.7: Dashboard loyalitas dan perilaku penumpang


Gambar 2.7 menunjukkan bahwa tier Basic mencatat 16.450 tiket, Gold 6.709 tiket, dan Platinum 1.841 tiket. Rata-rata `net_ticket_revenue` menunjukkan pola yang berbeda: Platinum memiliki nilai tertinggi sebesar Rp222.565, diikuti Gold Rp219.270 dan Basic Rp217.614. Nilai ini mencakup pajak, sedangkan visual Python mengikuti gross revenue pada query Bab 1.6 yang dihitung dari tarif setelah diskon sebelum pajak.

Rata-rata poin yang diperoleh berada pada kisaran 21,74–22,25 poin per transaksi, sedangkan rata-rata poin yang ditukarkan berada pada kisaran 1,08–1,16 poin per transaksi. Pada data sintesis ini, aktivitas memperoleh poin lebih dominan daripada penggunaan poin.



Dashboard Aktivitas Transaksi Loyalitas

Tren Transaksi Loyalitas Bulanan



Gambar 2.8: Dashboard aktivitas transaksi loyalitas

2.5.4 Dashboard Aktivitas Transaksi Loyalitas

Dashboard pada Gambar 2.8 menggunakan `fact_loyalty_transaction`. Terdapat 12.510 transaksi EARN dan 1.418 transaksi REDEEM. Total poin yang diperoleh mencapai 545.913 poin, sedangkan penukaran tercatat sebagai mutasi negatif sebesar 27.680 poin.

Aktivitas transaksi meningkat pada Juni serta kembali naik pada November dan Desember. Pola tersebut konsisten dengan skenario peak season yang dimasukkan saat pembangkitan data. Nilai negatif pada transaksi REDEEM dipertahankan agar arah perubahan saldo dapat dibedakan dari perolehan poin.

2.6 PEMBAHASAN

Ketiga dashboard menunjukkan bahwa fact table pada data mart dapat digunakan sesuai proses bisnisnya. Dashboard operasional menghubungkan gangguan perjalanan dengan dampak finansial, sedangkan dua dashboard loyalitas membedakan profil penjualan tiket dari mutasi poin. Pemisahan ini menjaga agar metrik pada grain tiket, penumpang-leg, dan transaksi poin tidak saling menggandakan nilai.

Dashboard Tableau menyediakan tooltip dan filter sesuai konteks visual. Grafik batang menggunakan label angka agar perbandingan tidak hanya bergantung pada warna. Workbook disimpan sebagai `visualisasi-bus-antarkota.twbx` sehingga relationship, calculated field, worksheet, dashboard, dan sumber CSV dapat dibuka kembali sebagai satu paket.

Data yang digunakan bersifat sintesis sehingga pola yang terlihat tidak dapat digeneralisasi sebagai kondisi operator bus nyata. Missed connection rate yang tinggi juga perlu dibaca bersama jumlah observasinya. Hubungan gangguan perjalanan dengan repeat booking masih berupa asosiasi dan memerlukan analisis lebih lanjut sebelum digunakan untuk menarik kesimpulan kausal.



2.7 KESIMPULAN

Tableau dan Python-based tools telah menggunakan keluaran data mart yang sama. Tiga dashboard Tableau mendukung analisis operasional, komersial, dan loyalitas, sedangkan dashboard Python menyajikan lima visual yang mengikuti business questions dan query verifikasi. Metrik yang menggunakan definisi sama menghasilkan angka yang konsisten, sedangkan perbedaan gross dan net revenue dijelaskan sesuai kolom yang digunakan.